

Dashboard Analítico em R para Visualização Interativa, Modelagem Temporal, e Geração de Relatórios Parametrizados Aplicados aos Registros de Licenciamento de Veículos

**Gabriel Baia da Silva¹, Mário Diego Rocha Valente¹,
Kleber Bezerra Salim¹, Tito Félix de Oliveira¹, Vinicius Duarte Lima²**

¹ Analista de Trânsito - Departamento de Trânsito do Estado do Pará (DETRAN-PA)

² Professor Dr., Faculdade de Estatística - Universidade Federal do Pará (UFPA)

`gabriel@hotmail.com, diego.vatente@gmail.com, kleber.salim@detran.pa.gov.br`

`tito.felix@detran.pa.gov.br, viniciussantos@ufpa.br`

Abstract. *This paper presents the development of an analytical dashboard in R for interactive visualization, temporal modeling, and parameterized report generation regarding the vehicle fleet in the state of Pará, Brazil. The architecture integrates the Shiny and Quarto frameworks, utilizing Apache Arrow for data optimization. Predictive modeling for fleet growth up to 2031 compared statistical approaches (ARIMA family) and deep learning methods (LSTM and GRU). The SARIMAX model achieved the best overall fit ($R^2 = 0.7240$), while the GRU model presented the lowest predictive error ($MAPE = 5.19\%$). To ensure scalability and high availability, a DevOps workflow based on containerization and orchestration (Podman, GitLab CI/CD, and Kubernetes) was implemented. The project highlights the feasibility of combining data science, machine learning, and modern orchestration to support government management and public transparency.*

Resumo. *Este trabalho apresenta o desenvolvimento de um dashboard analítico em R para a visualização interativa, modelagem temporal e geração de relatórios parametrizados da frota veicular do estado do Pará. A arquitetura integra os frameworks Shiny e Quarto, utilizando Apache Arrow para otimização de dados. A modelagem preditiva do crescimento da frota até 2031 comparou abordagens estatísticas (família ARIMA) e de aprendizado profundo (LSTM e GRU). O modelo SARIMAX obteve o melhor ajuste global ($R^2 = 0,7240$), enquanto o GRU apresentou o menor erro preditivo ($MAPE = 5,19\%$). Para assegurar escalabilidade e alta disponibilidade, implementou-se um fluxo DevOps embasado em containerização e orquestração (Podman, GitLab CI/CD e Kubernetes). O projeto evidencia a viabilidade de unir ciência de dados, aprendizagem de máquina e orquestração moderna no apoio à gestão governamental e transparência pública.*

1. Introdução

O crescimento acelerado da produção de dados governamentais tem ampliado a necessidade de mecanismos capazes de transformar grandes volumes de informações em instrumentos efetivos de transparência pública, apoio à tomada de decisão e formulação de políticas públicas baseadas em evidências [Janssen et al. 2012]. No contexto da administração pública brasileira, iniciativas voltadas à abertura e disseminação de dados passaram a ganhar maior relevância após a promulgação da Lei de Acesso à Informação (Lei nº 12.527/2011), estabelecendo diretrizes para disponibilização ativa de informações institucionais à sociedade [Brasil 2011].

Segundo o Radar Nacional da Transparência Pública [ATRICON 2025], embora os índices de transparência tenham apresentado evolução significativa nos últimos anos, ainda existem lacunas relacionadas à disponibilização estruturada de informações analíticas em diversos setores governamentais, especialmente em áreas relacionadas à mobilidade urbana e gestão do trânsito. Nesse cenário, órgãos executivos de trânsito passaram a demandar soluções computacionais capazes de integrar processamento estatístico, visualização interativa e disseminação automatizada de informações em ambientes acessíveis ao público externo.

A crescente complexidade dos ambientes analíticos contemporâneos impulsionou a adoção de plataformas integradas para ciência de dados e visualização interativa. Tradicionalmente, ferramentas de *Business Intelligence* (BI) proprietárias têm sido adotadas por instituições públicas. No entanto, essas soluções frequentemente esbarram em limitações de customização, algoritmos *black-box* e altos custos de licenciamento *vendor lock-in*. Esse panorama motivou uma maior aproximação entre análise estatística robusta e desenvolvimento de sistemas web de código aberto [Wickham and Grolemund 2017].

Nesse contexto, a linguagem R destaca-se por sua ampla utilização em aplicações estatísticas, mineração de dados e construção de aplicações analíticas reativas [Chang et al. 2026]. Paralelamente, frameworks como Shiny possibilitam o desenvolvimento de dashboards interativos sem a necessidade de implementação tradicional em múltiplas linguagens de front-end e back-end, garantindo a integração nativa com modelos de inteligência artificial de fronteira.

No estado do Pará, o Departamento de Trânsito (DETRAN-PA) administra uma base de dados veiculares associada ao Registro Nacional de Veículos Automotores (RENAVAM), composta por milhões de registros históricos. A elevada dimensionalidade dessas informações espaço-temporais, associada à necessidade de indicadores de motorização e projeções preditivas, torna indispensável a utilização de arquiteturas analíticas escaláveis. O desafio se acentua ao lidar com dados de cidades do interior, onde a esparsidade dos registros históricos exige técnicas avançadas de engenharia de *features* e *deep learning* para garantir a convergência de modelos [Knaflitz 2019].

Antes do desenvolvimento desta solução, solicitações estatísticas veiculares eram atendidas manualmente, resultando em elevada demanda operacional e lentidão na disseminação contínua de informações. A ausência de ferramentas interativas restringia a exploração dinâmica por gestores públicos, pesquisadores e cidadãos interessados em compreender os padrões de crescimento e distribuição da frota veicular.

Diante desse contexto, este trabalho apresenta o desenvolvimento de um sistema analítico integrado baseado na linguagem R, utilizando Shiny e Quarto para a construção de dashboards interativos e geração de relatórios parametrizados sobre a frota do DETRAN-PA. A arquitetura incorpora ETL otimizado via formato columnar Apache Arrow [Richardson et al.

2026], modelagem estatística de séries temporais, redes neurais e integração contínua baseada em orquestração de microsserviços [Burns et al. 2016].

No componente analítico, empregou-se modelos da família ARIMA [Box and Jenkins 1970], com variáveis exógenas (SARIMAX), além de arquiteturas baseadas em Redes Neurais Recorrentes, como *Long Short-Term Memory* (LSTM) [Hochreiter and Schmidhuber 1997] e **Gated Recurrent Unit** (GRU). A geração automatizada de documentos em Quarto Markdown ampliou a capacidade de disseminação de informações técnicas por município e categoria veicular, assegurando reprodutibilidade computacional [Xie et al. 2018].

A solução desenvolvida também incorpora práticas de *DevOps* voltadas à ciência de dados (MPOs), integrando containerização (*Podman*), *pipelines* (GitLab CI/CD) e orquestração (*Kubernetes*), garantindo escalabilidade em ambiente de nuvem governamental [Humble and Farley 2010; Burns et al. 2016].

O objetivo central deste trabalho é desenvolver uma arquitetura analítica integrada para disponibilização pública de estatísticas da frota veicular do DETRAN-PA. Como contribuição adicional, o trabalho demonstra, de forma inédita na literatura nacional, a viabilidade de unificar o ecossistema R (Arrow, Shiny, Quarto e Keras/TensorFlow) sob governança de *Kubernetes* no apoio à transparência pública de dados de mobilidade.

2. Trabalhos Relacionados

O uso de plataformas analíticas interativas voltadas à transparência pública e exploração de dados governamentais tem crescido significativamente, impulsionado pelas iniciativas de governo digital [Janssen et al. 2012]. Nesse cenário, dashboards analíticos passaram a desempenhar um papel estratégico.

Diversos estudos têm explorado o Shiny em contextos governamentais. [Kuo et al. 2019] desenvolveram um dashboard interativo para monitoramento epidemiológico utilizando dados espaciais e séries temporais em R, demonstrando como aplicações reativas ampliam a disseminação em tempo real. [Fay et al. 2021] destacam o potencial do Shiny na construção de plataformas reprodutíveis, enfatizando a integração com bibliotecas estatísticas. Contudo, em aplicações de mobilidade pública, o desafio do volume de dados em memória frequentemente inviabiliza arquiteturas Shiny tradicionais que não utilizem esquemas *out-of-memory*.

No domínio da mobilidade urbana, [Wang et al. 2020] utilizaram séries temporais para previsão do crescimento automotivo em centros urbanos, evidenciando a importância preditiva no planejamento viário. Em abordagens administrativas, [Barros et al. 2017] discutem o uso de ARIMA e SARIMA em dados com sazonalidade e tendência. Mais recentemente, modelos de aprendizado profundo (LSTM e GRU) vêm sendo aplicados a séries temporais complexas [Ghojogh and Ghodsi 2023], apresentando excelente desempenho ao capturar dependências não lineares e múltiplos fatores externos.

Além da camada analítica, a reprodutibilidade computacional tem sido uma barreira. Ferramentas como Quarto e R Markdown integram código e texto paramétrico [Xie et al. 2018]. Na esfera da infraestrutura analítica escalável, a engenharia de software voltada a dados (*Data-Ops* / *MLOps*) tornou-se imperativa [Humble and Farley 2010]. Tecnologias como *Kubernetes* [Burns et al. 2016] garantem isolamento, escalabilidade e alta disponibilidade de modelos de *machine learning* expostos via interfaces interativas.

Embora existam trabalhos sobre dashboards em R, observa-se uma carência de arquiteturas na literatura científica que integrem simultaneamente: processamento *lazy-loading* colunar, visualização interativa, previsão por aprendizado profundo e *deployment* escalável via Kubernetes no escopo de departamentos de trânsito. Este trabalho supre tal lacuna ao consolidar uma esteira analítica governamental completa.

3. Materiais e Métodos

A aplicação web foi desenvolvida integralmente no ecossistema R. A sua escolha justifica-se pela aderência unificada a todo o ciclo de vida do dado: desde as extrações via APIs, modelagem estatística, inferência via grafos computacionais (com *TensorFlow* no *backend*), até o delineamento da interface web. Os dados têm como origem o banco relacional interno do DETRAN-PA, gerido pela Diretoria de Tecnologia da Informação (DTI).

3.1. Arquitetura de Dados Otimizada com Apache Arrow e Parquet

O processo de Extração, Transformação e Carga (ETL) foi implementado utilizando o pacote *tidyverse* [Wickham et al. 2019], responsável pela sanitização, estruturação e padronização geométrica da base. Para lidar com a volumetria massiva sem incorrer em gargalos de memória RAM do servidor R, as tabelas originais foram transmutadas para o formato colunar *.parquet* e orquestradas pelo *framework arrow* [Richardson et al. 2026].

A utilização do Apache Arrow possibilita leituras do tipo *zero-copy* e operações de *lazy loading*. Isso significa que consultas analíticas realizadas via *dplyr* [Wickham et al. 2026] como filtros demográficos temporais (*filter*, *group_by*) são convertidas em planos de execução otimizados diretamente no disco (*pushdown* de predicados), subindo para a memória apenas o vetor resultante estritamente necessário para a plotagem gráfica do usuário, conferindo altíssima responsividade ao *dashboard*.

3.2. Interface e Reatividade Web

A aplicação utiliza o *framework Shiny* organizado no padrão *User Interface* (UI) e *Server*. A UI utiliza o pacote *bs4Dash* (baseado em Bootstrap 4) para prover responsividade tátil em dispositivos móveis. O componente servidor rege os grafos de reatividade estatística. O sistema conta com tabelas dinâmicas renderizadas em React.js via *reactable* [Lin 2026], integração de geoprocessamento em mapas coropléticos poligonais (*leaflet* [Cheng et al. 2025]) e séries interativas vetorizadas (*echarts4r* [Coene 2026]). O macrofluxo estrutural é delineado na Figura 1.




Figura 1. Arquitetura estendida do sistema: do processamento lógico e armazenamento colunar à implantação interativa.

4. Modelagem Estatística e Modelos Preditivos de Deep Learning

Adotou-se a abordagem de *storytelling* analítico de Knafllic (2019) para projetar os dados espacialmente e temporalmente. As seções a seguir fundamentam os algoritmos preditivos empregados.

4.1. Modelos Estatísticos Clássicos (Família ARIMA)

Os modelos estatísticos clássicos pertencentes à família ARIMA são amplamente empregados por sua capacidade nativa de absorver tendências seculares e padrões de autocorrelação [Box and Jenkins 1970]. O modelo base **ARIMA(p,d,q)** é dado pela Equação (1).

$$\phi(L)\Delta^d y_t = \theta(L)\varepsilon_t \quad (1)$$

Em que p é o componente autorregressivo, d é o grau de diferenciação integrativa e q a ordem de médias móveis. O operador de defasagem é L e ε_t o ruído branco. A sazonalidade de 12 meses observada no faturamento de IPVA e licenciamentos é tratada no $SARIMA(p, d, q)(P, D, Q)_{12}$, Equação(2).

$$\phi(L)\Phi(L^{12})\Delta^d \Delta_{12}^D y_t = \theta(L)\Theta(L^{12})\varepsilon_t \quad (2)$$

Para mitigação de anomalias econômicas, aplicou-se o modelo avançado $SARIMAX(p, d, q)(P, D, Q)_{12}$, Equação (3), que incorpora uma matriz de regressores exógenos (X_t).

$$\phi(L)\Phi(L^{12})\Delta^d\Delta_{12}^D y_t = \theta(L)\Theta(L^{12})\varepsilon_t + \beta X_t \quad (3)$$

O vetor X_t modelou de forma exógena as retrações macroeconômicas sofridas pelo Brasil (2013–2017), servindo como intervenção de "pulso" para garantir a estabilidade assintótica a longo prazo.

4.2. Redes Neurais Recorrentes e Modelagem Tensorial (GRU)

Para a modelagem estocástica e captura de não linearidades severas de longo alcance, projetaram-se arquiteturas de *Deep Learning*: **LSTM** (*Long Short-Term Memory*) e **GRU** (*Gated Recurrent Unit*). A implementação foi codificada utilizando `keras` e `tensorflow` via R, otimizada com Adam e backpropagation-through-time (BPTT).




Figura 2. Célula LSTM [Ghojogh and Ghodsi 2023]




Figura 3. Célula GRU [Ghojogh and Ghodsi 2023]

Enquanto a LSTM possui um custo computacional maior devido ao uso de três *gates* (esquecimento, entrada e saída), a GRU otimiza esse processo fundindo os estados ocultos nos gates de atualização e redefinição [Cho et al. 2014]. Para resolver o problema de ausência de granularidade temporal nas cidades do interior do estado (esparsidade de amostras), este trabalho propõe uma abordagem de **engenharia de tensores multidimensionais**, ilustrada na Figura 4.




Figura 4. Esquema da modelagem de dados para o algoritmo GRU empregado.

Ao invés de instanciar dezenas de modelos independentes para cada município, utilizou-se uma decomposição estatística (isolando tendência e ruído com Z-score) para compor uma matriz de 145 colunas (municípios) acoplada aos rezagos temporais. Esse arranjo resulta num *tensor de entrada global* enviado ao GRU. Essa estratégia impõe que a camada densa transfira o conhecimento de crescimento de polos urbanos maiores para as dinâmicas escassas de polos menores.

4.3. Subsistema de Relatórios Parametrizados (Quarto)

O ecossistema analítico culmina na geração automatizada de documentos. O servidor *Shiny* intercepta as coordenadas de filtros (espaço, tempo e tipologia) inseridas pelo usuário na UI e as encapsula nos metadados YAML de um documento mestre Quarto Markdown (.qmd) via argumento `params`.

Isso força a execução isolada de uma *thread* R no *background* que realiza consultas otimizadas via *arrow*. O Quarto compila gráficos vetorizados (via *ggplot2*) e tabelas gramaticais (via *gt*), transmutando-os em código *LaTeX*. Acoplado a um preâmbulo institucional de geometria e identidade visual (*HEADER.tex*), o motor *TinyTeX* gera um PDF de altíssima fidelidade e o retorna via *download* no front-end, eliminando a dependência manual de elaboração de boletins gerenciais e mitigando falhas humanas na prestação de contas governamental.

4.4. Metodologia de Deployment e Integração Contínua (DevOps)

Para garantir resiliência e alta disponibilidade, implementou-se um fluxo *DevOps* e CI/CD (Integração/Entrega Contínuas), ilustrado na Figura 5. O ecossistema *Podman* [Podman 2026] atua na criação da imagem imutável do sistema operacional Linux que embala o código R, suas dependências sistêmicas (C++) e o código fonte.




Figura 5. Esquema da arquitetura de *deployment* escalável e integração CI/CD.

O repositório é gerenciado via *GitLab* CI, automatizando os testes e enviando as imagens para o *Registry*. O cluster *Kubernetes* [Burns et al. 2016] consome essas imagens, orquestrando réplicas de contêineres (*Pods*) conforme a demanda. Um dos principais desafios técnicos de aplicações assíncronas baseadas em soquetes (*Shiny*) sob balanceamento de carga é a perda de estado. Isso foi solucionado configurando-se o *Ingress Controller* do *Kubernetes* com "afinidade de sessão" (*sticky sessions* via *cookies*). Tal técnica, combinada com protocolo criptografado estrito (WSS - *WebSocket Secure*), garante que requisições longas, como a compilação paralela de pesados PDFs em *LaTeX* pelo *Quarto*, não sofram *timeout* ou interrupções de rota.

A Taxa de Motorização, indicador essencial para engenheiros de trânsito e sociólogos, dimensiona o cruzamento entre densidade veicular e projeções demográficas municipais do IBGE. A Figura 8 exibe a curva de saturação veicular do estado.



Figura 8. Taxa de Motorização sobre os Veículos Registrados no Estado do Pará.

5.1. Resultados da Modelagem e Avaliação Preditiva

Para subsidiar tomadas de decisões a longo prazo, o sistema expõe o painel de Previsão Analítica (Figura 9). Como a arquitetura estipula que a inferência preditiva ocorra de maneira agnóstica na fase de pré-processamento para não onerar o tempo de resposta do *host*, os vetores resultantes até o horizonte temporal de 2031 foram precalculados, salvos no sistema de arquivos e carregados reativamente no Shiny.

Projeção da Frota por Localidade (2026 - 2031)

A tabela abaixo detalha a estimativa total acumulada da frota veicular até 2031. Os valores apresentados consideram a base real consolidada de dezembro de 2025, acrescida progressivamente da projeção de crescimento calculada pelo modelo SARIMAX de acordo com sua respectiva localidade.

Região de Integração: Todos as Regiões

Município (relativo à região escolhida): Todos (clique ou digite para escolher especificamente)

15 resultados por página

Município / Região	2026	2027	2028	2029	2030	2031
PARÁ (Geral)	3.214.267	3.552.678	3.951.298	4.423.368	4.980.911	5.639.997
BELEM	623.680	693.350	774.963	872.714	988.798	1.126.657
ANANINDEUA	223.628	254.474	292.359	339.506	397.901	470.185
MARABÁ	175.193	191.038	208.582	228.232	250.126	274.535
PARAUPEBAS	167.425	182.140	197.884	214.671	232.618	251.812
SANTAREM	154.453	162.257	169.957	177.895	185.436	193.166
CASTANHAL	123.953	136.697	151.680	169.467	190.518	215.420
REDENCAO	90.400	97.109	104.409	112.353	120.998	130.404
ALTAMIRA	83.115	87.313	91.602	96.003	100.528	105.190
ITAITUBA	69.106	72.378	75.651	78.924	82.197	85.469
PARAGUINHAS	58.846	62.345	65.997	69.806	73.781	77.928

Figura 9. Painel de Previsões Temporais e Comparação de Modelos

Os resultados preditivos foram avaliados fundamentalmente em cima do Erro Percentual Absoluto Médio (MAPE) e da Raiz do Erro Quadrático Médio (RMSE), métricas robustas para dados de trânsito, dadas pelas formulações matemáticas padrão:

$$MAPE = \frac{100\%}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad ; \quad RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (4)$$

Entre os algoritmos estatísticos, o SARIMAX capturou de forma exímia os resíduos sazonais de 12 meses (IPVA) e as quebras estruturais induzidas por instabilidades fiscais anteriores. Ele obteve um MAPE de 5,78% e coeficiente explicativo global (R^2) de 0,7240 (Figura 10).



Figura 10. Previsão estatística de crescimento obtida com o modelo SARIMAX.

Nas redes neurais complexas, o cenário difere. O LSTM enfrentou o clássico dilema da explosão de gradiente com dados escassos, gerando alta dispersão. Entretanto, a otimização algorítmica e topológica executada sobre o GRU, embasada no Tensor Global Multidimensional (descrito na metodologia), resultou em previsões extremamente fiéis ao comportamento biológico das curvas (Figura 11).




Figura 11. Projeção suavizada obtida com a arquitetura tensorial do GRU.

As métricas comparativas consolidadas de validação (*test-set evaluation*) entre as metodologias testadas estão expostas na Tabela 1.

Tabela 1. Comparação das métricas de desempenho no conjunto de validação dos modelos testados.

Modelo	MAPE (%)	MAE	RMSE	AIC	BIC	R^2
LSTM	9,07	1,803	2,292	189,70	190,67	0,2581
GRU	5,19	1,129	1,634	181,57	182,54	0,6230
ARIMA	9,18	1,855	2,203	188,74	189,71	0,3150
SARIMA	6,75	1,406	1,660	181,94	182,91	0,6111
SARIMAX	5,78	1,198	1,398	177,83	178,80	0,7240

A eficácia do algoritmo GRU se evidenciou na obtenção do menor erro da rodada ($MAPE = 5,19\%$). Sua matriz simplificada de dois gates reduziu o montante paramétrico que necessitava ser aprendido, tornando-se imune ao *overfitting*. A engenharia preditiva combinada (145 municípios x 84 meses efetivos) alimentou a rede neural com 12.180 exemplos de treinamento, viabilizando o entendimento do crescimento como um tecido interligado.

Em suma, ambos os modelos de ponta (SARIMAX para variância explicada e GRU para mitigação de erro absoluto) apontaram para o mesmo limiar logístico: um acréscimo explosivo de cerca de 60 mil novos veículos circulantes anualmente, saturando a infraestrutura das principais rodovias estaduais até 2031.

Do ponto de vista governamental, o acréscimo contínuo estimado e evidenciado pelos modelos preditivos na ordem de milhares de veículos gera consequências sistêmicas de amplo aspecto. Em primeira instância, o aumento acentuado da taxa de motorização acende o alerta para o esgotamento do planejamento urbano contemporâneo, pressionando diretamente as pastas governamentais a remodelar a estrutura rodoviária, semafórica e ampliar fortemente a disponibilidade de modais multimodais eficientes.

A capacidade do algoritmo de Deep Learning (GRU) de atuar em rede com dados transversais e alcançar um erro marginal de apenas 5% transforma-o num ativo crucial de inteligência institucional. Paralelamente, prever com precisão a malha veicular permite à Secretaria da Fazenda (SEFA) estimar, em níveis muito granulares, a arrecadação trilionária de licenciamentos e IPVA ao longo da década, alinhando despesas públicas a receitas fidedignas. O rigor estocástico garantido pelo SARIMAX isolando o choque econômico reitera a tese de que soluções algorítmicas conjuntas (*ensemble thinking*) são indispensáveis em análises estatais complexas.

Ao converter tais fluxos matemáticos intrincados em um Dashboard Shiny aberto e relatórios Quarto dinâmicos gerados em segundos, o DETRAN-PA não apenas extinguiu o processamento manual moroso das coordenações de estatística, mas materializou o espírito central da Lei de Acesso à Informação. Trata-se do rompimento do sigilo burocrático e da ascensão de uma era onde a sociedade civil, a academia e o gestor visualizam assincronamente as mesmas inferências tecnológicas, promovendo uma fiscalização cidadã em larga escala sobre a evolução estrutural e os padrões de mobilidade da sua própria região.

6. Considerações e Trabalhos Futuros

Este trabalho propôs, implementou e validou uma arquitetura analítica escalável e reproduzível orientada à transparência ativa dos dados de trânsito do Estado do Pará. O arcabouço construído sob a linguagem R consolidou metodologias díspares de forma harmoniosa: consultas

lazy em gigabytes de dados operadas via Apache Arrow, interatividade fluida orquestrada pelo reator web do Shiny, e editoração científica em LaTeX/Quarto de alta fidelidade entregue sem sobrecargas operacionais ao usuário final.

Na seara preditiva, a orquestração do processamento tensorial de dados regionais permitiu que as Redes Neurais Recorrentes (GRU) se igualassem e superassem os algoritmos clássicos em termos de acurácia, mitigando os desafios de escassez histórica de municípios do interior. Do lado da Engenharia de Software, a estabilização do ecossistema via contêineres e topologia de alta disponibilidade no Kubernetes demonstra que ferramentas *open-source* de *Data Science* possuem absoluta robustez para sustentar sistemas de alto tráfego em governos.

Para trabalhos futuros, o horizonte natural desta arquitetura caminha em direção ao monitoramento contínuo da letalidade e sinistralidade de trânsito. Planeja-se a migração da arquitetura estática de banco relacional para uma infraestrutura de mensageria assíncrona, incorporando o *Apache Kafka* para realizar inferências preditivas via stream processing (processamento em tempo real de acidentes e infrações). Essa evolução técnica alavancará a capacidade do Estado de realizar bloqueios rodoviários e operações táticas balizadas em predições baseadas em dados vivos e geolocalizados de mobilidade urbana.

Referências

- Box, G. E. and Jenkins, G. M. (1970). Time series analysis: Forecasting and control. *Holden-Day, San Francisco*.
- Burns, B., Grant, B., Oppenheimer, D., Brewer, E., and Wilkes, J. (2016). Borg, omega, and kubernetes. *Communications of the ACM*, 59(5):50–57.
- Cheng, J., Karambelkar, B., and Xie, Y. (2025). *leaflet: Create Interactive Web Maps with the JavaScript 'Leaflet' Library*. R package.
- Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. (2014). Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*.
- Coene, J. (2026). *echarts4r: Create Interactive Graphs with 'Echarts JavaScript'*. R package.
- Ghojogh, B. and Ghodsi, A. (2023). Recurrent neural networks and long short-term memory. *arXiv preprint*.
- Lin, G. (2026). *reactable: Interactive Data Tables for R*. R package.
- Podman (2026). *Podman: A tool for managing OCI containers and pods*.
- Richardson, N., Cook, I., Crane, N., Dunnington, D., François, R., Keane, J., Moldovan, D., and Ruiz, J. (2026). *arrow: Integration to 'Apache' 'Arrow'*. R package version 18.0.0.
- Wickham, H., Averick, M., Bryan, J., Chang, W., McGowan, L. D., François, R., Grolemond, G., Hayes, A., Henry, L., Hester, J., et al. (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43):1686.
- Wickham, H., François, R., Henry, L., and Müller, K. (2026). *dplyr: A Grammar of Data Manipulation*. R package.